



ESCUELA COLOMBIANA DE INGENIERÍA JULIO GARAVITO

FORMULARIO PARA PROYECTOS DE INVESTIGACIÓN E INNOVACIÓN MAESTRÍA EN CIENCIA DE DATOS

**DIRECCIÓN MAESTRÍA EN CIENCIA DE DATOS
Bogotá, D.C.**

1. Información general del proyecto

Título del proyecto	Modelado Predictivo Híbrido en Redes de Tributación: Estimación de la Suscripción y el Impacto Comercial de Convenios de Doble Tributación (CDT) para Colombia utilizando Graph Neural Networks		
Duración del proyecto (meses) mínimo 8 meses para profundización, 12 meses para investigación	6 meses		
Costo total del proyecto	\$0 COP		
Unidad académica a la que pertenece el director:	Maestría en ciencia de datos	Máximo nivel académico del líder del proyecto:	Doctorado X Magíster
Dirección electrónica	juan.correa-n@escuelaing.edu.co		Dedicación (horas-semana):

Campos y áreas de desempeño al (los) cual(es) aplica el proyecto:

Medio ambiente (agua, aire residuos, contaminación, gestión ambiental)	
Infraestructura (de transporte, energética de telecomunicaciones, de edificaciones, de acueducto y alcantarillado)	
Materiales (materiales de construcción, industriales, nanomateriales, biomateriales)	
Cibernética (señales e imágenes, control y automatización, ingeniería de la rehabilitación)	
Energía (consumo energético, sistemas de generación y distribución de energía, sistemas de la gestión integral de la energía)	
Manufactura y servicios (sistemas productivos de bienes y servicios, sistemas de distribución de bienes y servicios, gestión de la calidad)	
Información y conocimiento (tecnología de la información, gestión de información y conocimiento, diseño y construcción de software, modelado empresarial)	X
Ciencias sociales y humanas (sistemas económicos, sistemas de gestión de las organizaciones, semiótica y lenguajes y símbolos, educación, tecnología y sociedad, culturas instituciones y desarrollo)	X
Ciencias básicas (matemáticas, estadística, ciencias naturales)	X

2. Información del personal participantes en el proyecto**

Nombre Estudiante – Énfasis que cursa	Rol que desempeña en el proyecto	Unidad académica a la que pertenece	Máximo nivel académico	Dedicación (horas- semana)	Tiempo
Huber Camilo Borja Amaya - Profundización	Estudiante	Maestría en Ciencia de Datos	Profesional	10	horas

Nombre	Breve descripción de la experiencia del investigador en el área de investigación, proyectos realizados.

3. Descripción del proyecto

3.1. RESUMEN DEL PROYECTO

Este proyecto busca predecir la suscripción de convenios para evitar la doble tributación que puede suscribir Colombia con otros países mediante el modelado de redes buscando nuevos posibles enlaces y sus respectivos pesos representados por el comercio. Se busca elaborar esta herramienta como una fuente de facilitación que puede mejorar el control fiscal, la tributación y el comercio entre países importantes para Colombia. Además, este proyecto proporcionaría a entidades nacionales como la DIAN y el Ministerio de Hacienda y Crédito Público la priorización basada en datos para dirigir los esfuerzos de negociación hacia los socios con mayor impacto. También, podrá ayudar en el campo de la ciencia de datos abarcando integralmente recomendaciones de artículos que se representan en dos fases que son la predicción de enlaces representando los convenios y la predicción de los pesos que representa el comercio.

3.2. PLANTEAMIENTO DEL PROBLEMA

La problemática por abordar es la predicción de convenios para evitar la doble tributación. Estos convenios son promovidos para la Organización para la Cooperación y Desarrollo Económico (OCDE) y la Organización de Naciones Unidas (ONU) para aumentar los flujos de inversión, normalizar la tributación entre países y prevenir la evasión fiscal (OCDE, 2019). Estos convenios son resultado de una negociación entre las administraciones tributarias de países que buscan que sus contribuyentes no paguen impuestos en los dos países por los ingresos de las actividades económicas que desarrollan en estos. Además, estos documentos ofrecen una oportunidad de control fiscal por parte de las administraciones al facilitar el intercambio de información entre países que tienen amplia conexión comercial y el acceso oportuno a la ubicación de contribuyentes para posibles requerimientos.

Actualmente, países como México, Chile y Ecuador superan a Colombia con 46, 37 y 22 convenios respectivamente. Colombia tiene 15 convenios en vigencia superando a Perú que tiene 10 convenios. Los países con los que tienen convenio a su vez representan el 23,35% de las importaciones de Colombia según el DANE en el periodo enero a diciembre 2024¹. Esto sugiere una oportunidad de Colombia de poder entablar convenios para evitar la doble tributación con países que sean socios comerciales estratégicos y que puedan representar un aumento del comercio a mediano y largo plazo.

3.3. ESTADO DEL ARTE DE LA INVESTIGACIÓN O LA INNOVACIÓN PROPUESTA

La presente propuesta busca ampliar lo estudiado por los autores Erokhim y Zagler (2024)² quienes hicieron un modelo de aprendizaje supervisado de predecir los pares de países que tendrían un convenio para evitar la doble tributación con el algoritmo de random forest. Este trabajo sugiere un campo de investigación para predecir los nuevos convenios de tributación utilizando la predicción de enlaces en redes complejas y también sus pesos representados como el volumen de comercio que puede haber entre los países.

Con respecto a los convenios de doble tributación, actualmente hay evidencia que afirman que los acuerdos de doble tributación en el caso de la India (Hurrah, 2025)³, Turquía (Cevik, 2015)⁴ sí incrementa el flujo de inversión extranjera. Aún así, para el caso colombiano no se ha encontrado evidencia estadística que respalde el incremento de inversión extranjera directa Fillippo Aguilón et al. (2023)⁵.

¹ Datos obtenidos de <https://www.dane.gov.co/files/operaciones/IMP/anex-IMP-SerieHistoricasPais-ago2025.xls>

² Erokhim, D. and Zagler, M. (2024). Who will sign a double tax treaty next? a prediction based on economic determinants and machine learning algorithms. *Economic Modelling*, 139:106819. Obtenido de <https://doi.org/10.1016/j.econmod.2024.106819>

³ Hurrah, F. A. and Chisti, K. A. (2025). Exploring the impact of double taxation treaties on india's fdi: A panel data approach using the gravity model. *Research Square*. Obtenido de: <https://assets-eu.researchsquare.com/files/rs-6729617/v1/d72b2893-e863-4c04-8b14-ab3f8e3e86e9.pdf?c=1749483508>

⁴ Cevik, S. and Taşar, M. O. (2015). The impact of double tax treaties on foreign direct investments: Evidence from turkey's outward fdis. *Proceedings of International Academic Conferences 2504045*, International Institute of Social and Economic Sciences. Obtenido de: <https://ideas.repec.org/p/sek/iacpro/2504045.html>

La metodología aplicada para la predicción de enlaces va a ser el Variational Graph Autoencoder - Genetic Algorithm (VGAE - GA) obtenido de Li et al (2025)⁶ cuyo objetivo es establecer relaciones cooperativas potenciales entre países mediante el uso de módulos que obtienen información y sus hiperparámetros son optimizados mediante el Genetic Algorithm. Este algoritmo tendrá un enfoque temporal para la predicción de futuros convenios debido a que la suscripción de estos es el desenlace de una negociación a lo largo del tiempo. Por otro lado, para predecir el volumen de comercio, que serían los pesos de la red, se usará el Line Graph Neural Networks for Link Weight Prediction (LGLWP) obtenido Liang (2025)⁷ cuyo objetivo es predecir el peso o fuerza de los enlaces mediante transformaciones a la red extrayendo un subgrafo de los nodos a los cuales se quiere predecir el enlace, etiquetando los nodos según sus posiciones relativas, convirtiendo el subgrafo en uno de línea y aplicando Redes Neuronales Convolucionales las cuales estimarán el peso.

3.4. OBJETIVOS DEL PROYECTO

Objetivo General:

Desarrollar un modelo de predicción de suscripción de Convenios para evitar la Doble Tributación y su impacto en el volumen del comercio en Colombia mediante la aplicación de técnicas de predicción de enlaces y sus pesos en redes complejas.

Objetivos específicos:

- Estructurar una red compleja y temporal de los convenios suscritos a nivel mundial, donde los países son los nodos, los convenios vigentes son los enlaces y el volumen de exportaciones representa el peso de dichos enlaces para el período de 2000 a 2025.
- Recopilar y procesar los atributos de los nodos (países) que servirán como características para el modelo, incluyendo variables macroeconómicas como PIB y población, tasas de tributación, pertenencia a bloques económicos y distancia geográfica.
- Implementar un modelo de aprendizaje no supervisado (Improved Variational Graph Autoencoder with Genetic Algorithm, IVGAE-GA) para la predicción de futuros enlaces, identificando así los países con mayor probabilidad de suscribir un CDT con Colombia en el futuro.
- Aplicar un modelo de predicción de pesos (Line Graph-Based Link Weight Prediction, LGLWP) sobre los enlaces predichos para estimar el volumen de comercio (flujo de dinero) que un nuevo CDT podría generar, cuantificando así su impacto potencial.

3.5. METODOLOGÍA PROPUESTA

1. Elaborar la red de países y convenios

La red de convenios entre países sería obtenida a partir de la consulta a las páginas oficiales web de las administraciones tributarias que tienen convenio para evitar la doble tributación con Colombia.

Así, tenemos el grafo G para los años t del conjunto $T=\{2000, ..., 2025\}$ entonces hay un grafo $G_t=(V,E_t,W_t)$ donde V es el conjunto de nodos que serían los países, E_t son los enlaces que son si tienen o no convenio para evitar doble tributación y W_t sus pesos que sería el volumen de exportaciones del país i a j para cada t .

2. Recopilar los datos para atributos de los nodos

Los datos adicionales para la elaboración de los enlaces serían datos particulares de cada país como las siguientes sin limitarse a:

- PIB y población de cada país i para cada año t
- Tasas de tributación para personas a los cuales acobijan los convenios como el impuesto a la renta y al patrimonio
- Si el país pertenece a algún bloque económico como OCDE o Alianza del Pacífico
- Distancia entre países representada como la distancia entre las ciudades capitales

⁵ Fillippo Aguillón, L., Vélez López, I. A., and Victoria Simbaqueva, M. (2023). Análisis y evaluación de impacto de los acuerdos de doble tributación sobre los flujos de inversión extranjera directa en Colombia. Tesis de maestría, Universidad de los Andes. Obtenido de: <https://repositorio.uniandes.edu.co/entities/publication/f5774d2d-9e7a-4571-b08f-b495909d76a2>

⁶ Li, Y., Song, Y., Yao, Q., and Guan, X. (2025). A new link prediction model for grain trade networks based on improved variational graph autoencoder and genetic algorithm. *Applied Soft Computing*, 180:113336. Obtenido de: <https://link.springer.com/article/10.1007/s11227-025-07217-7>

⁷ Liang, J., Pu, C., Shu, X., Xia, Y., and Xia, C. (2025). Line graph neural networks for link weight prediction. *Physica A: Statistical Mechanics and its Applications*, 661:130406. Obtenido de: <https://www.sciencedirect.com/science/article/abs/pii/S0378437125000585>

3. Metodología predicción de enlaces Improved Variational Graph Autoencoder with Genetic Algorithm (IVGAE-GA)

La metodología se obtiene de Li et al. (2025)⁸ cuyo objetivo es establecer relaciones cooperativas potenciales entre países. El modelo se basa en el Variational Graph Autoencoder (VGAE), el cual está diseñado para manejar la incertidumbre y el ruido al aprender una distribución de probabilidad (media y varianza) para la representación latente de cada nodo, en lugar de un único valor puntual.

La adaptación temporal del modelo sería la siguiente: Primero, los vectores de embeddings, o representaciones latentes, de los nodos serán generados para cada grafo G_t extrayendo información desde el Dynamic Adaptive Graph Attention (DAGAN) y una red neuronal convolucional (CNN). Una vez generados los embeddings, el algoritmo procederá a fusionar la información y hallar la probabilidad de que exista un enlace entre el país i y el país j para cada año de acuerdo con sus características. Se puede hacer entonces un entrenamiento de los grafos para predecir los convenios del año 2025 y así predecir los siguientes.

El VGAE utiliza hiperparámetros que pueden ser optimizados con el Algoritmo Genético (GA) generando combinaciones aleatorias de hiperparámetros y evaluando sus rendimientos. Estos hiperparámetros son el canal de salida c , tasa de aprendizaje η , número de módulos DAGAN k , capas L , tasa de DropEdge p , y constante de escalado s .

Finalmente, el modelo es evaluado usando métricas como Área debajo de la curva (AUC) y Average Precision (AP), buscando valores más altos para indicar una mejor capacidad de predicción.

4. Predecir el peso mediante el método Line Graph-Based Link Weight Prediction (LGLWP)}

La metodología se obtiene de Liang (2025)⁹ cuyo objetivo es predecir el peso o fuerza de los enlaces. Así, se crea el subgrafo con el par de países que se espera que se firme convenio. Aplicando este subgrafo de un salto alrededor de cada enlace objetivo y se normalizarán los pesos w entre 0 y 1 tal que $w^* = e^{(-1/w)}$.

Cada nodo será etiquetado para establecer un orden consistente basado en las distancias ponderadas a los nodos objetivo que refleje el orden de los nodos en el subgrafo. Posteriormente, el subgrafo se convertirá en un grafo de línea en donde los nodos ahora representan los enlaces del subgrafo original dando así que el peso se convierte en un atributo del nodo. Durante esta transformación, la información estructural y los atributos de los nodos del subgrafo original se transfieren a los nodos del grafo de línea mediante una operación de concatenación, donde el atributo de un nodo en el grafo de línea se forma concatenando los atributos de sus dos nodos terminales correspondientes en el subgrafo original.

Luego, se emplean Redes Neuronales Convolucionales (GCN) para aprender embeddings, o representaciones vectoriales, de los nodos en este grafo de línea. Estos capturan información del vecindario de cada nodo en el grafo de línea. Finalmente, los resultados generados por la GCN alimentan a una red neuronal de dos capas totalmente conectadas. Esta red realiza la tarea de regresión para predecir el peso del enlace objetivo. El modelo se entrena minimizando el error cuadrático medio (RMSE), lo que permite a LGLWP aprender directamente las características de los enlaces y ofrecer una solución robusta y eficiente al problema de la predicción de pesos.

3.6. DISTRIBUCIÓN DE RESPONSABILIDADES PARA EL DESARROLLO DEL PROYECTO

- Estudiante de la maestría: Ejecutor principal y responsable de la ciencia de datos
- Tutor del proyecto de grado: asesoría científica y metodológica.

3.7. RESULTADOS/PRODUCTOS ESPERADOS

1. Artículo que sea publicable en el área de ciencia de datos

⁸ Li, Y., Song, Y., Yao, Q., and Guan, X. (2025). A new link prediction model for grain trade networks based on improved variational graph autoencoder and genetic algorithm. *Applied Soft Computing*, 180:113336. Obtenido de <https://doi.org/10.1016/j.asoc.2025.113336>

⁹ Liang, J., Pu, C., Shu, X., Xia, Y., and Xia, C. (2025). Line graph neural networks for link weight prediction. *Physica A: Statistical Mechanics and its Applications*, 661:130406. Obtenido de: <https://www.sciencedirect.com/science/article/abs/pii/S0378437125000585>

2. Un modelo de Machine Learning que pueda optimizar a priorización e identificación de aquellos paoss con mayor probabilidad de suscribir un acuerdo para evitar la doble tributación

3.8. ACTIVIDADES Y CRONOGRAMA DE TRABAJO

- *Elabore un cronograma con las fases o actividades científicas y tecnológicas del proyecto y los tiempos de desarrollo de cada una (presentarlo en hoja adicional si lo desea).*
- *Identifique los mecanismos previstos para el seguimiento, control y calidad del proyecto.*

Fase	Actividad	Duración	Semanas	Frecuencia de reuniones y entregables
Preparación y estructuración de datos	• Recolección de datos • Estructuración de la red • Métricas estructurales endógenas	4 semanas	1-4	• Reuniones semanales • Base de datos estructurada lista para el modelado
Implementación y modelado	• Implementación modelos random Forest para establecer línea base • Implementación y refinamiento del IVGAE-GA • Implementación y entrenamiento del LGLWP para predicción de	14 semanas	5-18	• Reuniones semanales • Código limpio con los modelos entrenados y resultados de predicción finales
Análisis y documentación	• Análisis de resultados y sensibilidad • Redacción del trabajo de grado • Revisión final y ajustes	7 semanas	19-25	• Reuniones quincenales • Documento para sustentar
Entrega del Trabajo de grado	• Conclusiones y recomendaciones • Entrega del trabajo de grado • Sustentación • Entrega de ajustes y modificaciones • Entrega final	8 semanas	26-33	• Reuniones quincenales • Documento final para entrega a biblioteca

Se utilizará un sistema de control de versiones en GitHub para seguimiento del código garantizando trazabilidad de los cambios y reproducibilidad de la implementación.

3.9. IMPACTOS ESPERADOS

- Impactos sobre la productividad y competitividad en el sector de desarrollo o áreas de desempeño relacionados
 - Acceso a nuevos mercados nacionales ó internacionales
 - Regiones y comunidades beneficiadas por el proyecto

POSIBLES PARES EXTERNOS EVALUADORES

Relacione mínimo 3 profesores externos que podrían ser evaluadores de su proyecto:

Nombre	Universidad	Dirección de correo	Teléfono
Guillermo Andrés Otero	Escuela Colombiana de Ingeniería Julio Garavito	guillermo.otero@alfaestadistica.com	

PARA LOS PROYECTOS QUE INVOLUCRAN SERES VIVOS, INCLUIR LOS SIGUIENTES ASPECTOS A LA PROPUESTA: NO APLICA

4. Resultados/productos del proyecto

Formule los resultados directos verificables que se alcanzarán con el desarrollo de los objetivos específicos del proyecto, indicando las características del nuevo producto, proceso o servicio. Tenga en cuenta la tipología descrita por Colciencias

Enumere los resultados del proyecto

Producto	Descripción

5. Presupuesto y fuentes de financiación (miles de pesos)

Todos los cuadros de presupuesto del proyecto deben estar diligenciados y totalizados

RUBROS		APOORTE ESCUELA	CONTRAPARTIDA				TOTAL
			GRUPO DE INVESTIGACIÓN		OTRA(S) INSTITUCIÓN(ES)		
			Efectivo	Especie	Efectivo	Especie	
HONORARIOS	Asesorías legales para trámites de patentes, asistencias técnicas.						0
	Reconocimiento a estudiantes (pregrado y posgrado)						0
CAPACITACIÓN (inscripción en cursos, presentación de ponencias (nacionales e internacionales))							0
GASTOS DE VIAJE (tiquete, alojamiento, manutención, anticipo de gasto de viaje)							0
INVERSIÓN	Equipo procesamiento de datos						0
	Equipo audiovisual						0
	Equipo médico y científico						0
	Maquinaria y Equipo						0
	Muebles y Enseres						0
SOFTWARE ESPECIALIZADO (Derecho uso de licenciamiento nuevo)							0
MANTENIMIENTO Y ADECUACIONES(mantenimiento equipo y reparaciones locativas)							0
MATERIALES E INSUMOS(insumos laboratorio, herramientas, seguridad industrial)							0
GASTOS DE TRANSPORTE	Taxis y buses						0
ÚTILES Y PAPELERIA	Fotocopias						0
	Otros útiles						0
INVERSIÓN BIBLIOTECA (libros, bases de datos).							0
							0
							0
MATERIAL DE DIFUSION Y PROMOCION DE RESULTADOS (Publicación en revista-Medios)							0
TOTAL							0

5.1 DESCRIPCIÓN GASTOS EN PERSONAL (miles de pesos)*

Nombres y Apellidos	Título		Función en el Proyecto	Dedicación Horas / Semana	No. de Meses	Fuentes				TOTAL	
	Formación Básica	Posgrado				APORTE ESCUELA	GRUPO DE INVESTIGACIÓN		OTRA(S) INSTITUCIÓN(ES)		
							Efectivo	Especie	Efectivo		Especie
										0	
										0	
										0	
TOTAL										0	

* Se debe diligenciar un cuadro similar para el caso de estudiantes de posgrado y pregrado que reciban reconocimiento académico. Este rubro no debe exceder el 40% del aporte solicitado a la Escuela.

5.2 DESCRIPCIÓN EQUIPOS QUE SE PLANEA ADQUIRIR (miles de pesos) ⁽¹⁾

Descripción	Cantidad		Justificación de su uso dentro del Proyecto	Fuentes					TOTAL
				APORTE ESCUELA	GRUPO DE INVESTIGACIÓN		OTRA(S) INSTITUCIÓN(ES)		
					Efectivo	Especie	Efectivo	Especie	
									0
									0
									0
									0
			TOTAL						0

⁽¹⁾ Se debe diligenciar un cuadro similar en el caso de: A. Software (Adquisición, programación y desarrollo) – B. Materiales e insumos – C. Servicios tecnológicos – D. Adecuación de infraestructura – E. Gastos de patentamiento o registro – F. Documentación – G. Material de promoción y difusión de resultados.

5.3 DESCRIPCIÓN PARTICIPACIÓN EN SEMINARIOS, CONGRESOS, ETC. (miles de pesos)

Descripción	Tema de la capacitación	Ciudad	No. de días	No. de personas	Costo de capacitación por persona	Fuentes					TOTAL
						APORTE ESCUELA	GRUPO DE INVESTIGACIÓN		OTRA(S) INSTITUCIÓN(ES)		
							Efectivo	Especie	Efectivo	Especie	
										0	
										0	

											0
											0
TOTAL											0

5.4 DESCRIPCIÓN VIAJES (miles de pesos)

Proveedor	Objetivo del viaje	Ciudad	No. días	No. personas	Costo de capacitación / persona	Costo estadía / persona	Fuentes					TOTAL
							APORTE ESCUELA	GRUPO DE INVESTIGACIÓN		OTRA(S) INSTITUCIÓN(ES)		
								Efectivo	Especie	Efectivo	Especie	
												0
												0
												0
TOTAL												0



DECLARACIÓN:

1. El estudiante declara ser consciente que cualquier tipo de fraude en este Trabajo de Investigación es considerado como una falta al reglamento de la Escuela Colombiana de Ingeniería. Firmar, entregar y presentar esta propuesta de Trabajo de Investigación implica expreso testimonio de que esta propuesta fue desarrollada de acuerdo con las normas establecidas por la Escuela Colombiana de Ingeniería.
2. El estudiante se compromete a seguir estrictamente las normas de derechos de autor. Así mismo, el estudiante no hará publicaciones, informes, artículos o presentaciones en congresos, seminarios o conferencias sin la revisión o autorización expresa del Director, quien representará en este caso a la Escuela Colombiana de Ingeniería.

FIRMAS

Estudiante

Director

Co-Director (si lo hubiere)*

Representante de Investigación

** Los requisitos para requerir un co-director se enuncian en los lineamientos de Trabajo de Investigación. En caso de requerirlo, se debe anexar a la propuesta de Investigación, un acuerdo firmado por las partes donde se consensuarán y propondrán las funciones a cumplir por el mismo co-director.*